

# 松阪工場におけるAI活用先の探索 ～モアレ検査の異物判定モデルの構築～



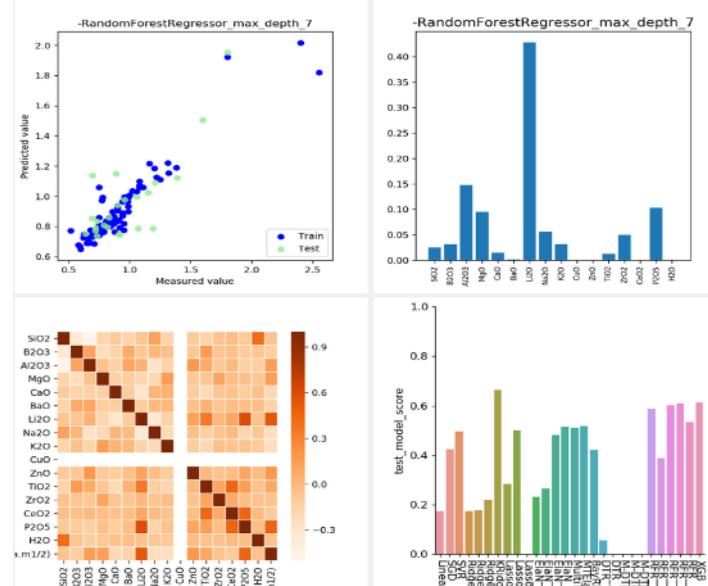
硝子研究所 3研  
齋藤、芹田

## ■ 硝子研におけるこれまでのAI活用実績

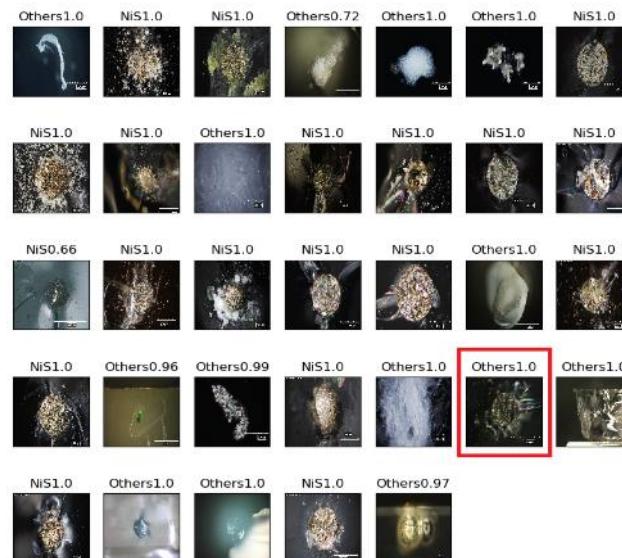
### 汎用AIツールの作成

“AIに関する知識がない人でも機械学習が使えるツール”というコンセプト

#### 機械学習プログラム “CAB”



#### 画像分類プログラム “Deeplearning for photos”



## ■ 硝子研におけるこれまでのAI活用実績

### 機械学習プログラム “CAB”

→ テーブルデータからの予測

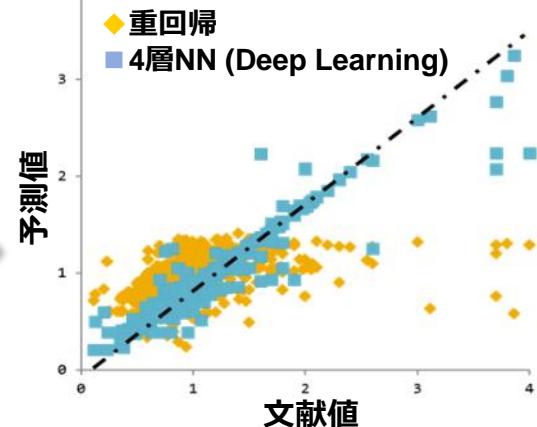
#### 教師データ

No.	GlassNo.	DataSource	Year	GlassNo.	SiO <sub>2</sub>	B2O <sub>3</sub>	Al <sub>2</sub> O <sub>3</sub>	MgO	CaO	TiO <sub>2</sub>	ZrO <sub>2</sub>	CeO <sub>2</sub>	P2O <sub>5</sub>	H <sub>2</sub> O	FractureT
1	12630	GP02-272	Japanese	2006	67.76	0	2.33	8.68	0	1.12	0	0	0	0	0.74
2	15670	GP02-307	Japanese	2012	62	0	13	3	0	2	0	0	0	0	0.89
3	676	Gl02-003	J.Ceramic	1988	71	0	1	0	0	16	0	0	0	0	0.7
5	2732	Gl06-037	J.American	1978	60	0	22.5	0	0	0	0	0	0	0	0.69
6	8883	Gl06-1916	NGF+Add	2001	55.15	0	14.38	0	0	0	0	0	0	0	0.81
7	6773	Gl03-156	Glas-Tect	1994	60	0	0	0	0	0	0	0	0	0	0.91
8	15805	GP05-307	USPatent	2012	67.2	10.6	10.6	2.9	0	0	0	0	0	0	0.9
9	9160	Gl05-207	J.Ceramic	2001	57	19	0	0	0	0	0	0	0	0	0.68
10	10541	GP03-225	USPatent	2002	66.42	0	4.76	3.44	0	1.69	0	0	0	0	0.65
11	15085	GP05-301	Japanese	2011	61.9	0	13	3	1	0.6	0	0	0	0	0.94
12	15805	GP05-307	USPatent	2012	66.2	7.6	11.3	5.3	0	0	0	0	0	0	0.9
13	2371	Gl02-0455	Physician	1980	85	0	0	0	0	0	0	0	0	0	0.8
14	14551	Gl02-298	J.Non-Cry	2010	66.7	0	0	0	0	0	0	0	0	0	0.74
15	4848	Gl02-1405	J.Material	1991	74.35	0	0	0	0	0	0	0	0	0	0.95
16	12457	GP05-268	Japanese	2005	65.48	0	0.57	22.97	0	0.47	0	0	0	0	0.875
17	15802	GP05-307	USPatent	2012	68.13	9.79	10.39	0	0	0	0	0	0	0	0.9
18	12432	GP02-268	Japanese	2005	65.13	0	3.58	15.4	0	1.43	0	0	0	0	0.87
19	5867	Gl07-1951	Non-Cry	1999	76	n	n	n	n	n	n	n	n	n	0.94

#### 機械学習

**CAB**  
CAB Analyze Bigdata

#### 出力結果



#### ● ガラス物性の予測 (重回帰、NN)

教師データに公開DB (Interglad) を用い、目的の破壊靱性値を有するガラス組成を予測

#### ● ポット形状最適化 (ベイス最適化)

教師データにシミュレーション結果を用い、目的の温度分布を有する炉の形状を全探索

## ■ 硝子研におけるこれまでのAI活用実績

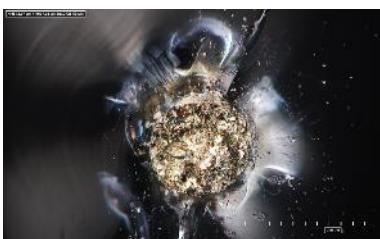
画像分類プログラム “*Deeplearning for photos*” → 画像データからの予測

- 欠陥分析の効率化

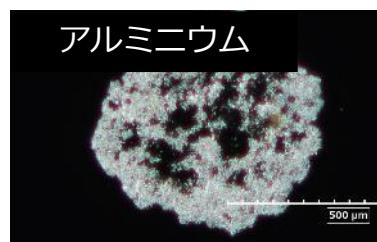
風冷強化ガラスの自爆が硫化ニッケル起因かどうかを写真から判定

2クラス分類 (Train 88枚、Test 33枚、学習回数100回) → 正答率97%

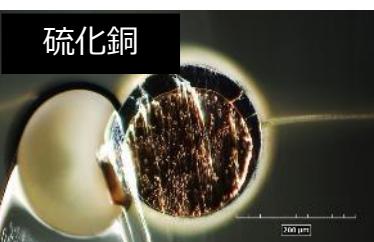
硫化ニッケル



or



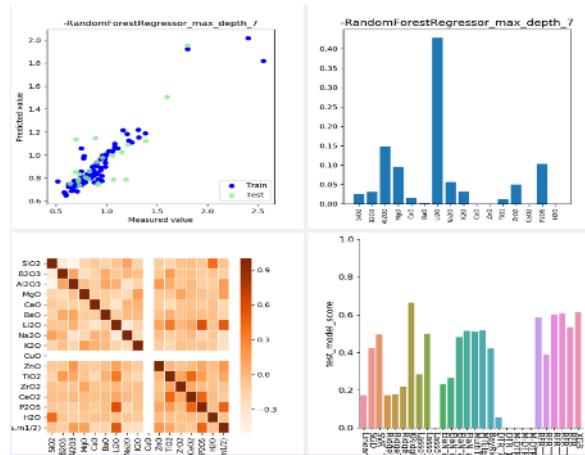
その他



## ■ 硝子研におけるこれまでのAI活用実績

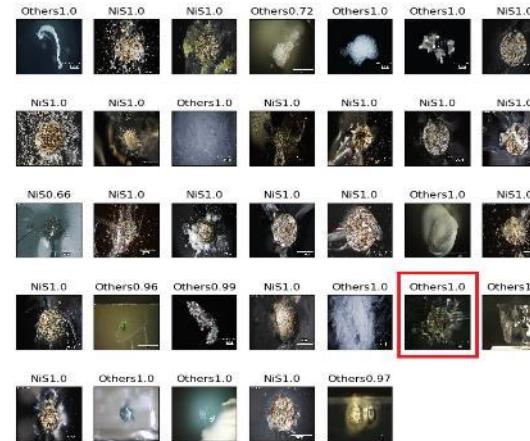
## 汎用AIツール

# 機械学習プログラム “CAB”



# 画像分類プログラム

## “Deep learning for photos”



- ✓ 簡単にパラメーター変更はできず、テーマ毎に最適なモデル構築や検証は難しい
  - ✓ 未経験者だとデータの選定や見方が分からず使いこなすのが困難

汎用ツールであるはずが活用されていない

# ■ なぜAI活用で失敗してしまうのか

## 失敗理由によくある3パターン

### 1. 「知識不足」

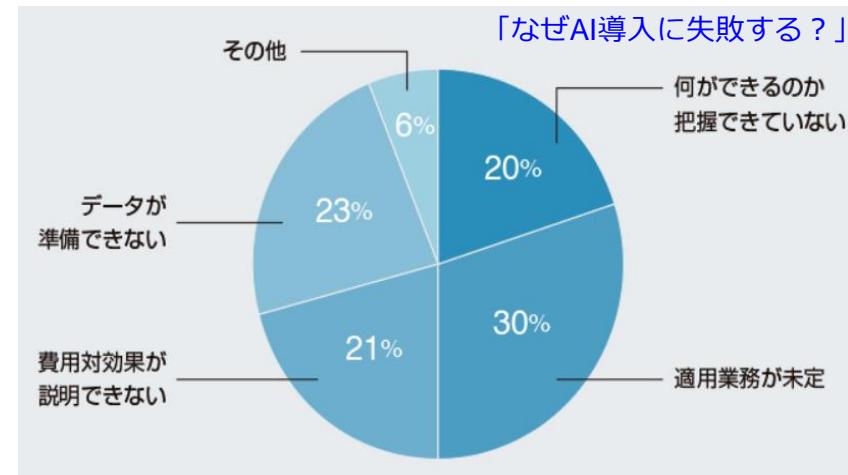
- AI導入に関して最低限のリテラシーを持っていない  
→ AI活用の前提となる基礎知識を習得し、AIリテラシーを養う

### 2. 「技術先行」

- 適用業務が曖昧で「とりあえずAI！」状態  
→ 課題先行で考えることの重要性を理解し、社内の潜在的なニーズを探る

### 3. 「組織の壁」

- データ準備、AI運用の協力体制が整っていない  
→ 協力関係部署でプロジェクトを組む  
迅速な経営判断を行う

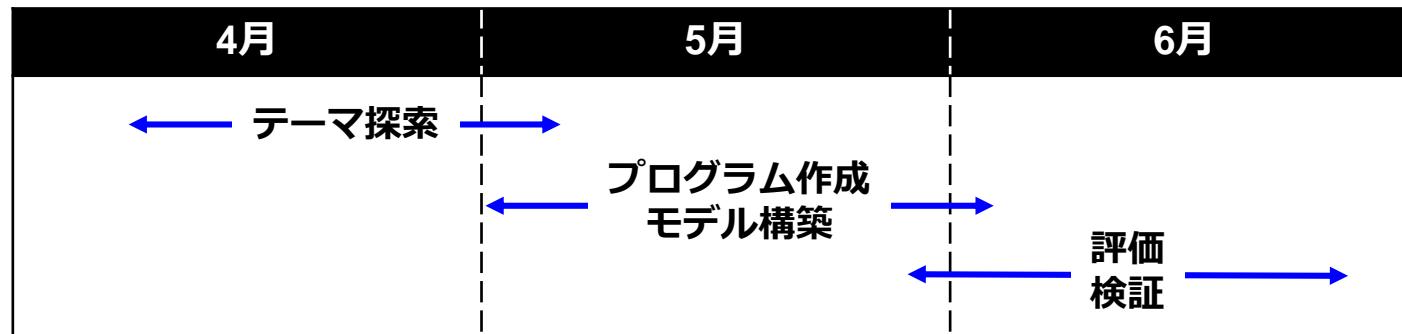


Softbank Future Stride 引用  
[https://www.softbank.jp/biz/future\\_stride/entry/ai/20190401/](https://www.softbank.jp/biz/future_stride/entry/ai/20190401/)

## ■ 検討した内容

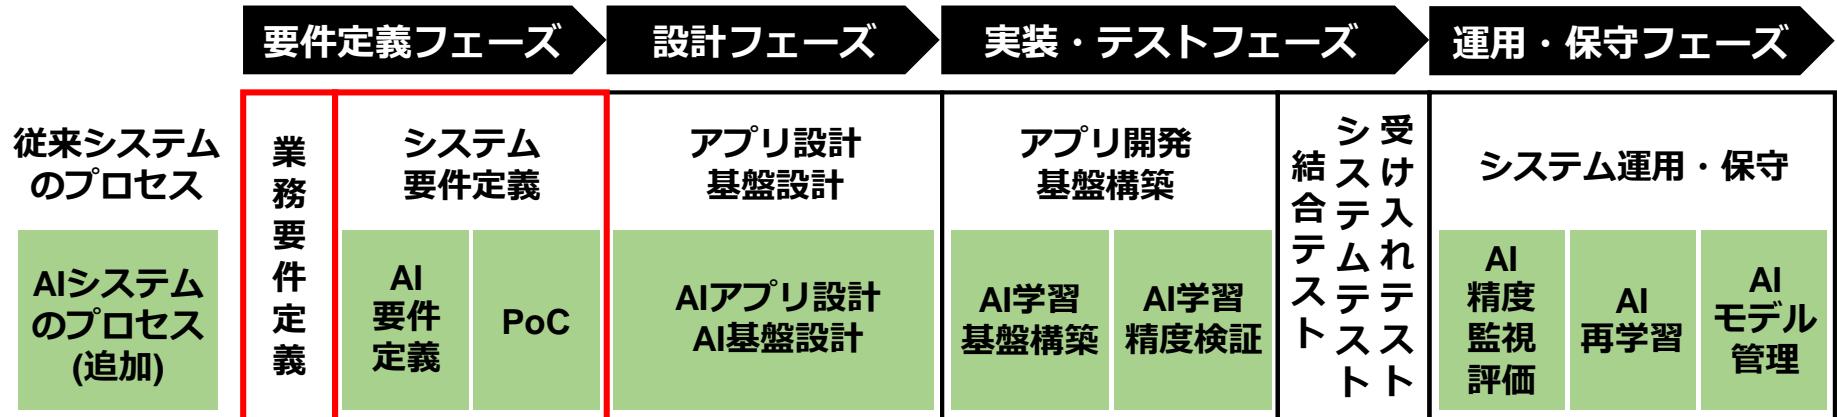
「AI活用の流れを知ること」と「課題の明確化」が大切

- 失敗しないAI活用方法を学ぶ (AIリテラシーの蓄積)
  - ✓ AI活用のワークフローとは？
  - ✓ 自社での運用方法は？硝子研の役割は？
- 松阪工場におけるAI(機械学習)活用テーマの探索
  - ✓ これまでの汎化型ツールではなく課題解決型のAI活用はできないか？
  - ✓ 研究所で蓄積した機械学習の知見が活かせるテーマはないのか？



※通常業務と並行して実施

## ■ AI導入に向けたプロセス

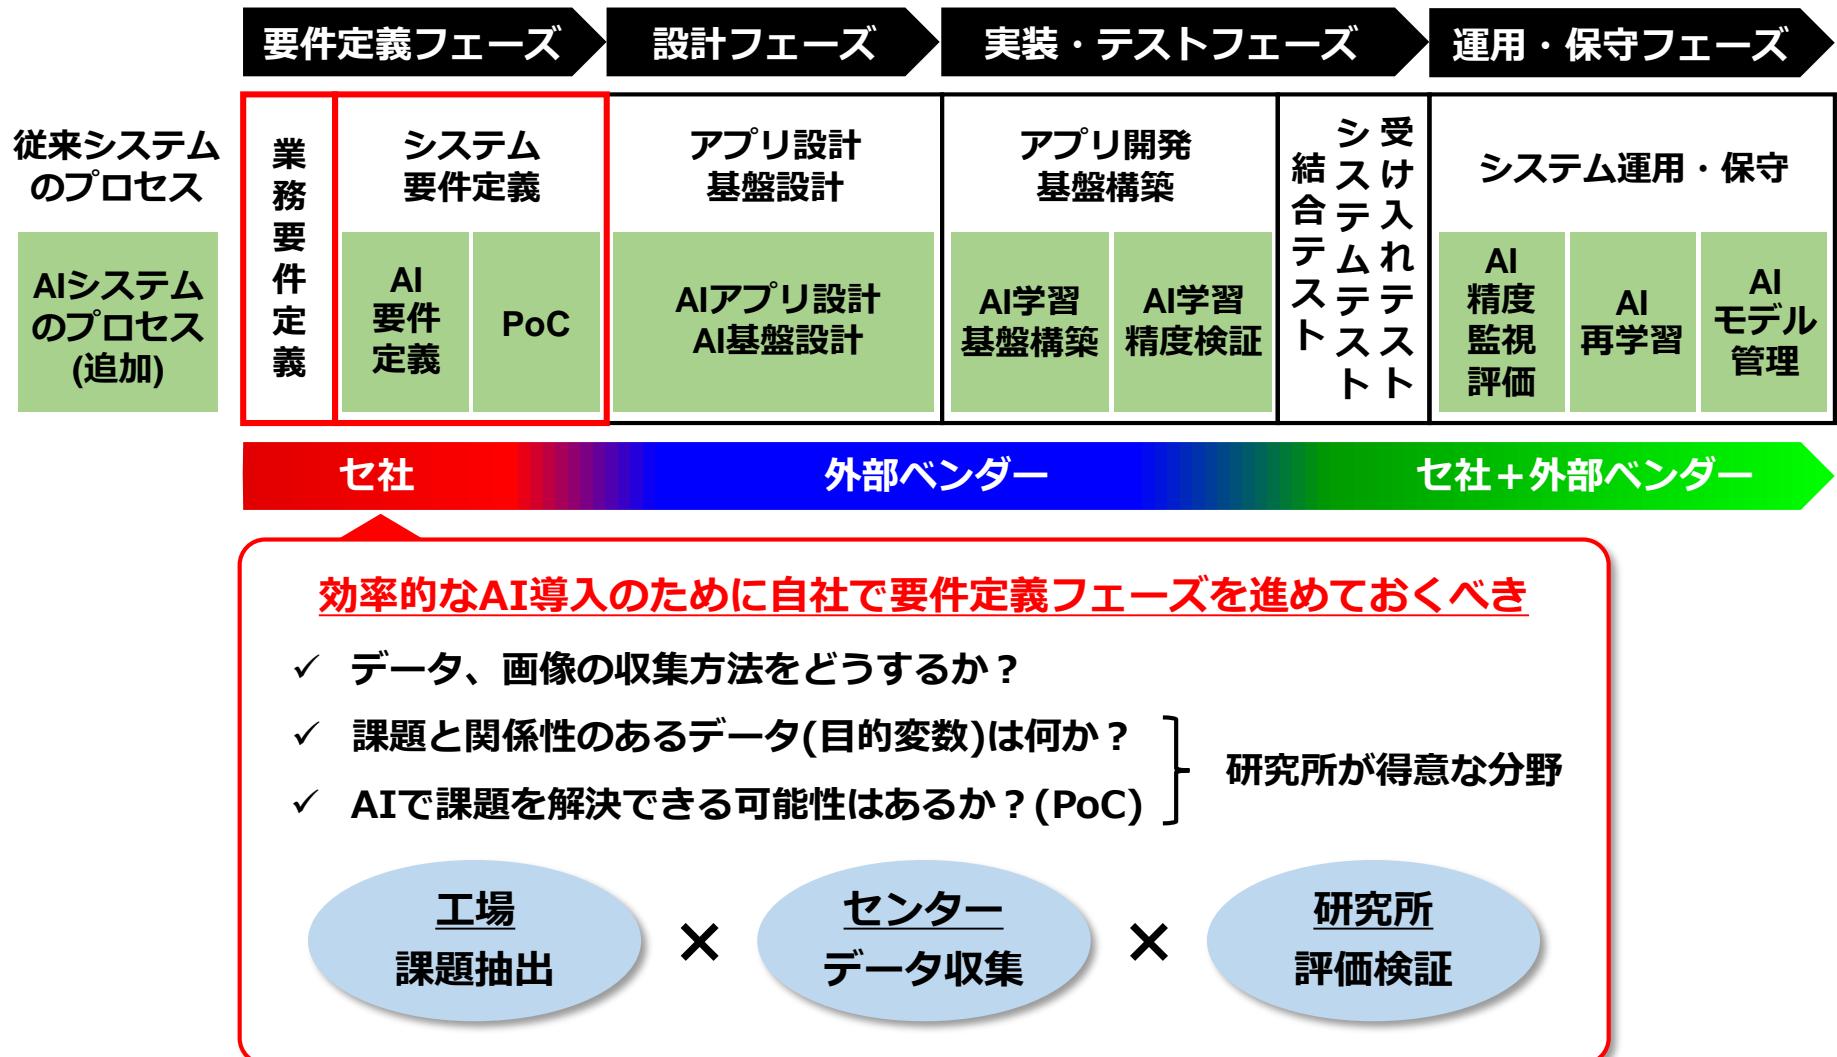


PoC(簡易検証)はベンダーも必ず実施する全フェーズを外部ベンダーに委託すべきか？

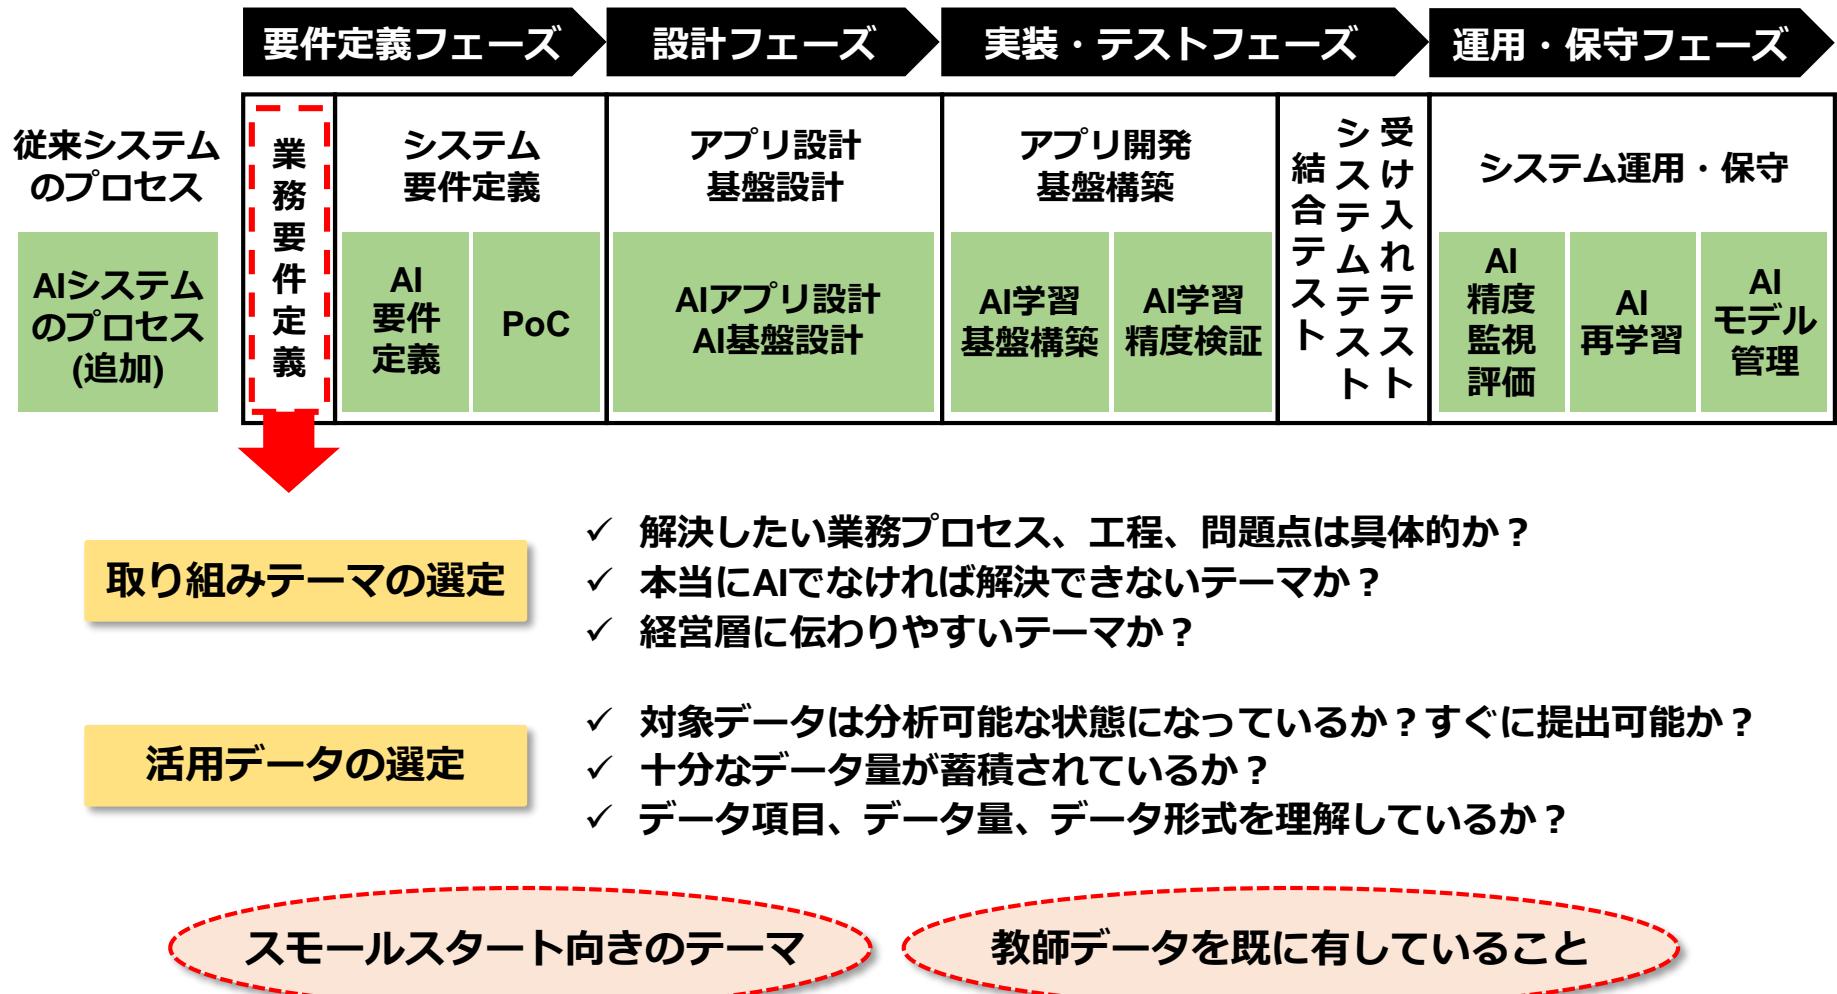
マイナーな分野は丸投げすると大抵失敗する

- 解決すべき課題の軸が定まらない
- 提供すべきデータがわからない
- 現場の意見が反映されていない 等

## ■ AI導入に向けたプロセス



## ■ AI導入に向けたプロセス



## ■ 社内ニーズの聞き込み調査

### 製造部関連 (フロート板)

- **色替え条件調整の簡素化**

品種切り替え時に投入する原料を調整し、光学特性等で判断している

→ 原料を投入してから特性に反映されるまでタイムラグがあり、正確なデータ収集が困難

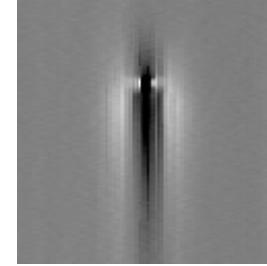
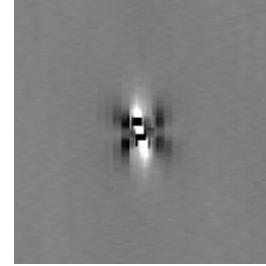
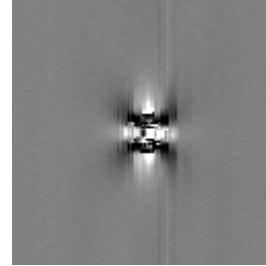
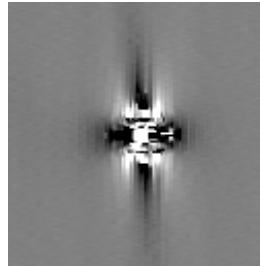
- **異物判別時間の短縮 (モアレ検査)**

検査装置にて異物が確認されたら実際に採断し、異物種に応じた対策を講じている

→ 過去1ヶ月分の画像データが蓄積されており、十分なデータ量を確保できる

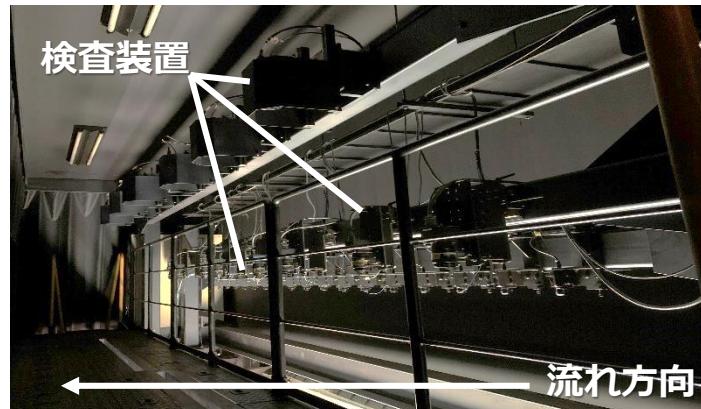
AIで置き換えるメリットがあり、スマールスタートに向いている

異物画像の一例



## ■ 分析対象テーマ：モアレ検査における異物判別

### 1. 徐冷後のモアレ検査にて異物の有無を確認



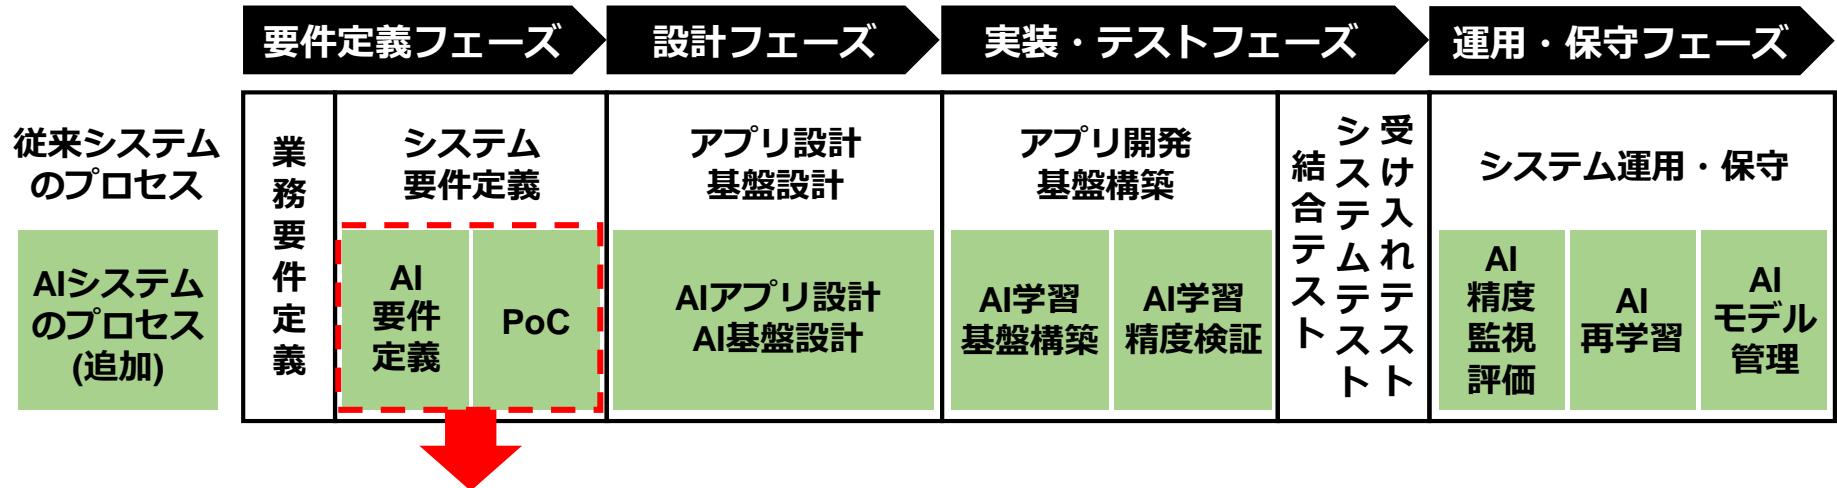
2. 異物が頻発したら採断して確認  
(詳細な分析を行うことも)

3. 発生した異物種によって  
生産条件を調整

- × 正確な異物判定までに時間を要するため生産条件へのフィードバックが遅くなる
- × ある程度経験値がない(ベテランじゃないと)と迅速な判別は難しい

**目的：「異物判別時間の短縮による生産効率の向上」**

## ■ AI導入に向けたプロセス：AI要件定義 & PoC



### AI要件定義

#### Step1. 計画・準備 (機能要件の整理)

- ・アルゴリズム
  - ・データの形式/粒度
  - ・例外ケースの検証方法
  - ・データ基盤の選定 (クラウド or オンプレミス)
  - ・システム稼働後の運用要件、リソース先の選定等
- ・精度の評価方法
  - ・分析対象期間
  - ・応答性能

### PoC (Proof of Concept, 概念検証)

#### Step2. 分析実行

- ・データセットの作成
- ・モデル構築



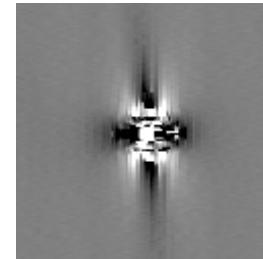
#### Step3. 評価検証

- ・構築したモデルの評価
  - 過学習の有無
  - 評価指標

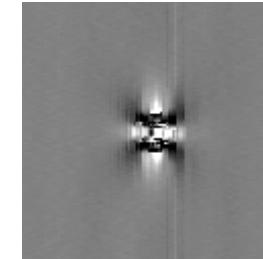
## ■ 使用データの準備

- 品種 : MFL2
- 異物種 : 6種
- 枚数 : 約1000枚
- 画素数 :  $128 \times 128$
- ファイル形式 : PNG (8bit)

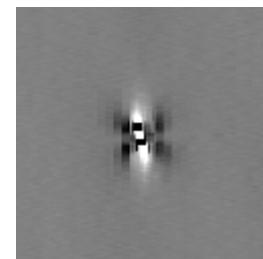
\*検証では4/27生産時のデータを使用



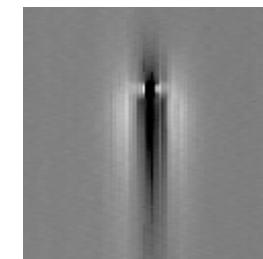
砂利



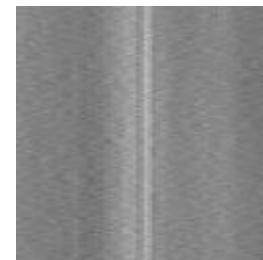
BB



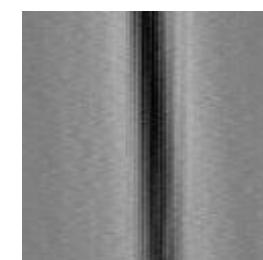
芒硝泡



落下物

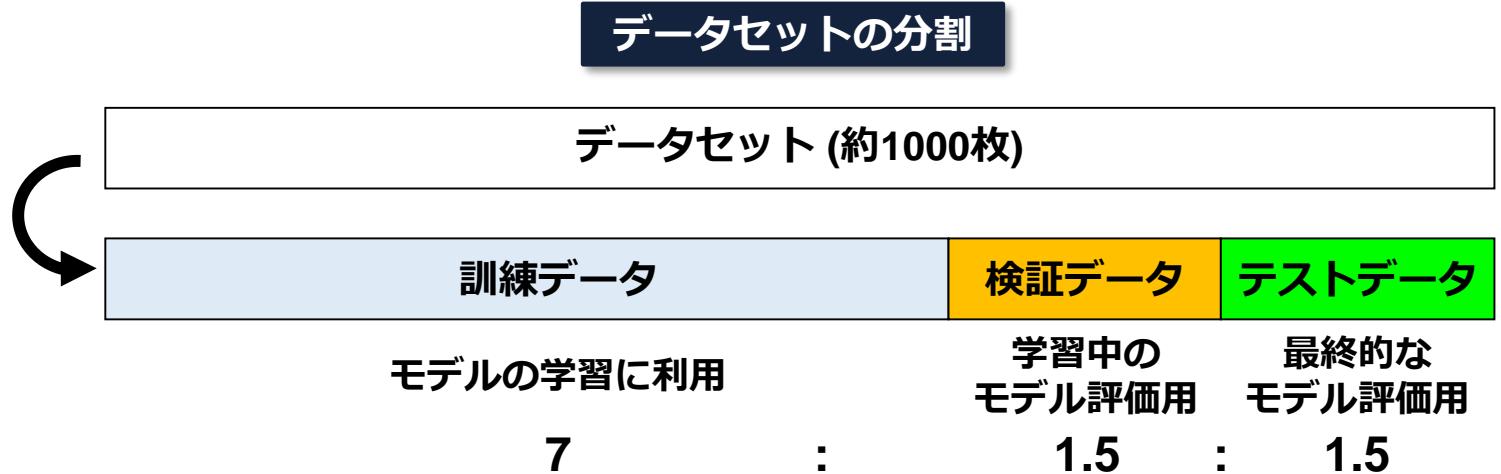


筋欠陥



リーム

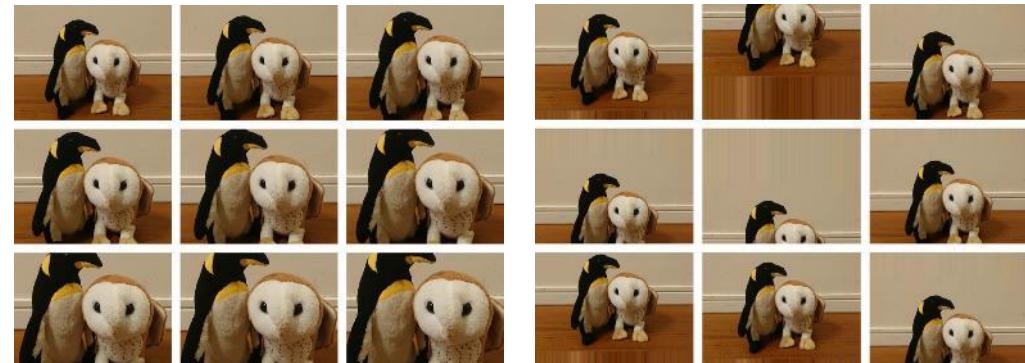
## ■ データセットの作成、前処理



### 学習画像の水増し (Image-Data-Generator)

K Keras

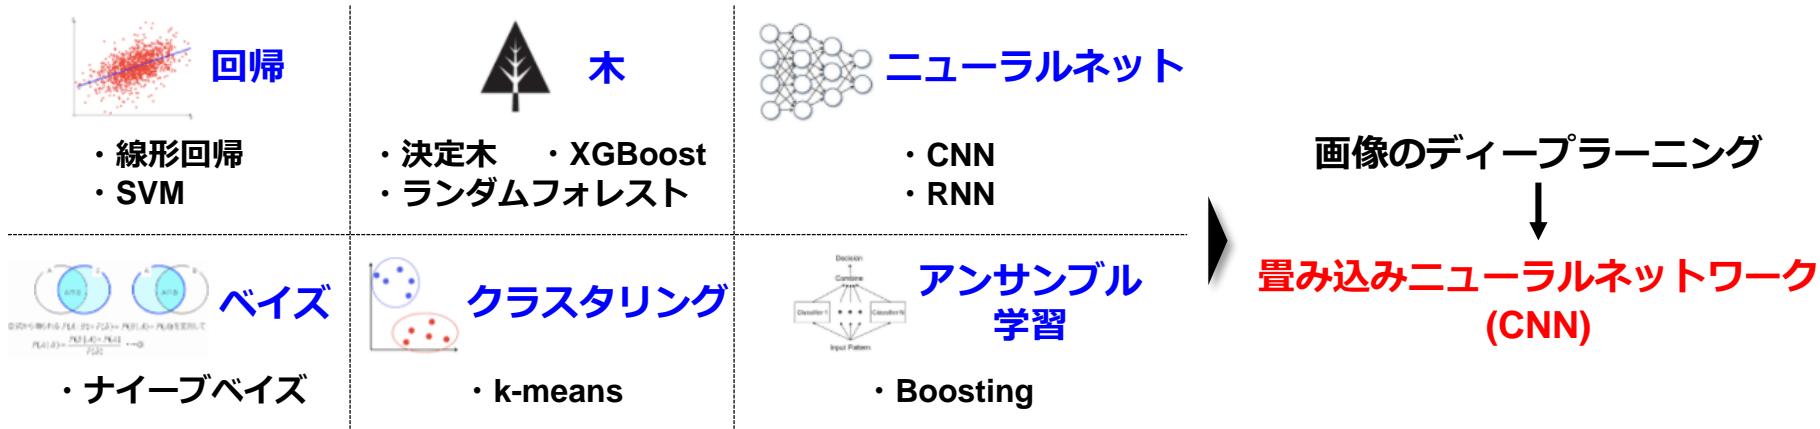
画素値変換  
拡大縮小  
上下左右反転  
上下左右平行移動  
シア一変換  
RGB補正



拡大縮小

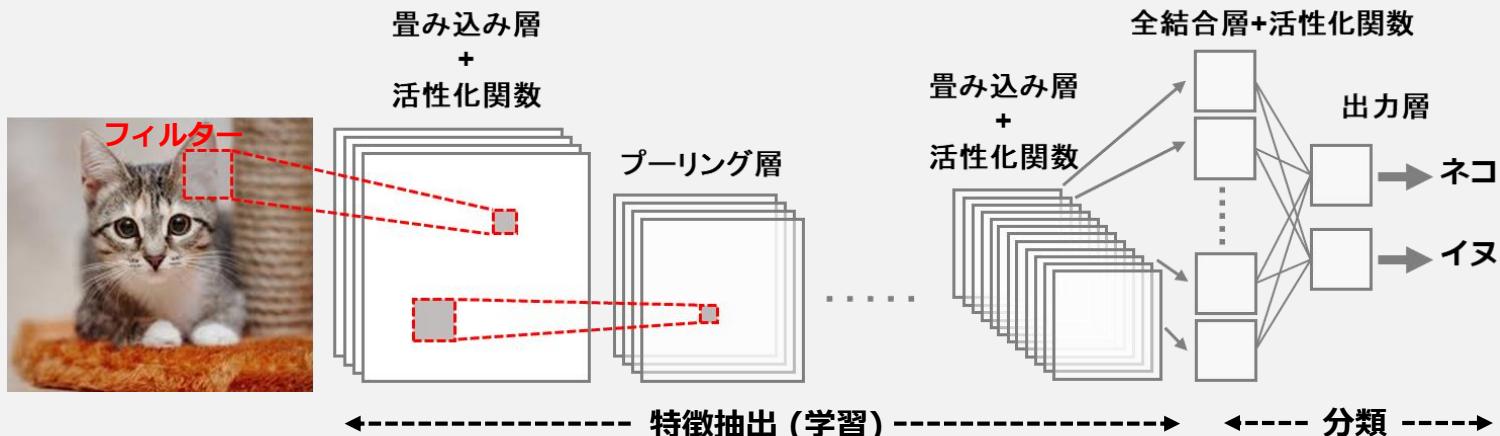
上下平行移動

## ■ アルゴリズムの選定



### CNNとは

局所領域の置み込み (フィルターによるエッジ抽出)とプーリング (画像の縮小)を繰り返す多層ネットワーク



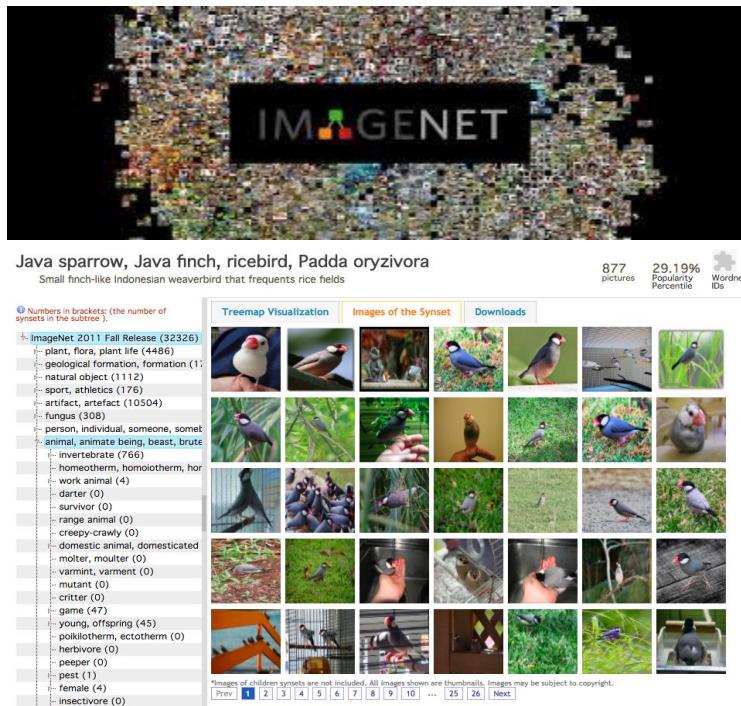
# ■ モデル構築

## 転移学習・ファインチューニングの活用

ディープラーニングに使用する学習データが少ないときは...

Kerasで提供されている学習済みモデルを再利用(転移学習)

1400万枚以上の画像を収録したImageNetで学習した有名な学習済みモデルが重みと共に提供されている



Model	Size	Top-1 accuracy	Top-5 accuracy	Parameters	Depth
VGG16	528MB	0.715	0.901	138,357,544	23
MobileNet	17MB	0.665	0.871	4,253,864	88
Xception	88MB	0.790	0.945	22,910,480	126
InceptionV3	92MB	0.788	0.944	23,851,784	159
ResNet50	99MB	0.759	0.929	25,636,712	168

<https://github.com/keras-team/keras-applications>

主要ベンダーも検証段階で転移学習を利用

**Albert**  
Analytical technology

画像分類

AlexNet      VGG16      SqueezeNet10      SqueezeNet11  
ResNet50      ResNet101      ResNet152      DarkNet19

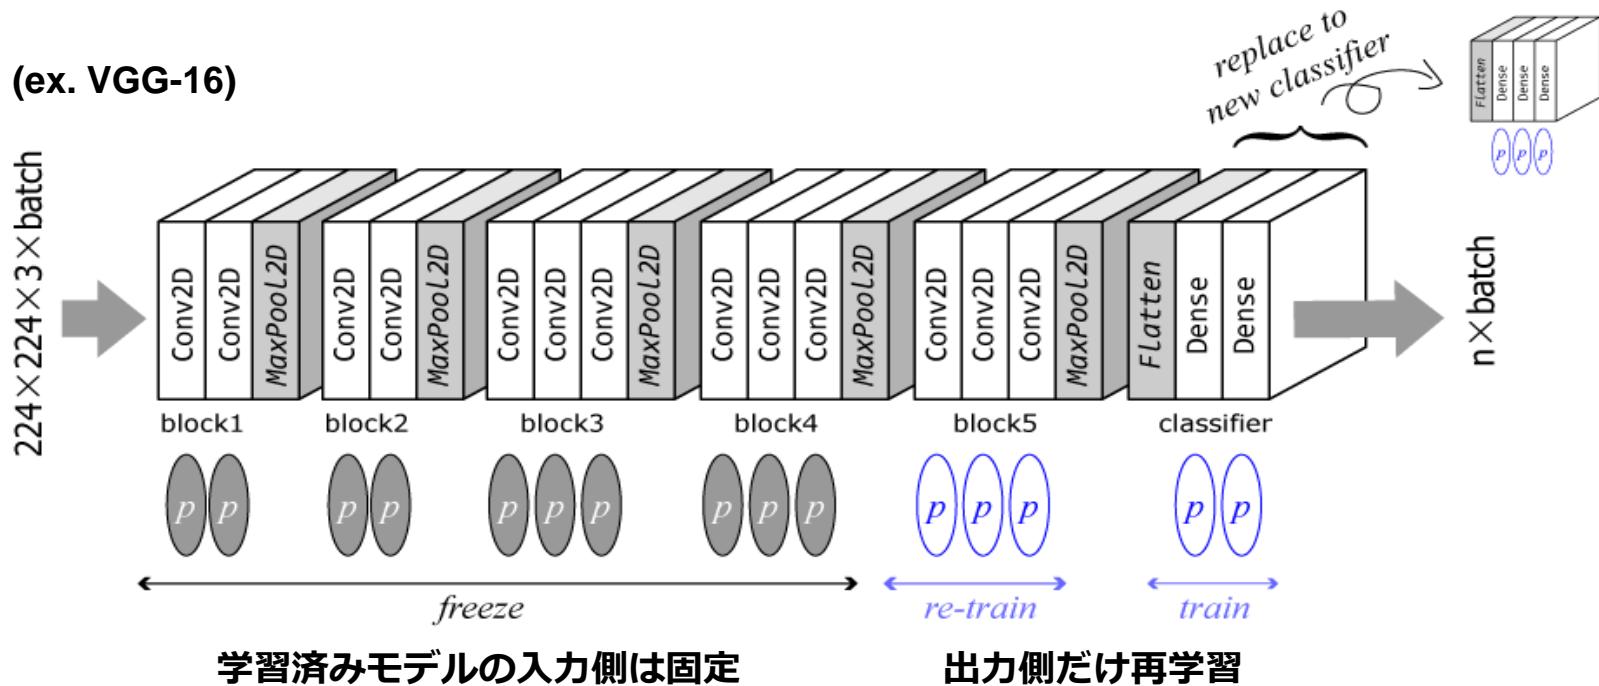
<http://www.image-net.org/index>

<https://www.slideshare.net/DeepLearningLab/20180921-dlab2>

## ■ モデル構築

### 転移学習・ファインチューニングの活用

既存の学習済モデルに最終出力層を付け替え、学習済みの重みのうち一部を再学習  
→ 「少量のデータ」 「短い学習時間」 で比較的精度の高い画像分類モデルの構築が可能



今回はVGG-16、Xception、MobileNetのファインチューニングを実施

## ■ 最適化するハイパーパラメータの選定

	意味	決定
パラメータ	モデルが持つ重み係数、バイアス	自動で決まる
ハイパーパラメータ	モデルの構造を決める、学習の設定	手動で決める

ハイパーパラメータは課題毎に最適化する必要がある

\*自動最適化ツール「Optuna」等もあるが、膨大な時間がかかる(らしい)

### ハイパーパラメータの例

学習率 : 重みパラメータを学習して更新する振り幅

Batch size : 1回に処理する件数

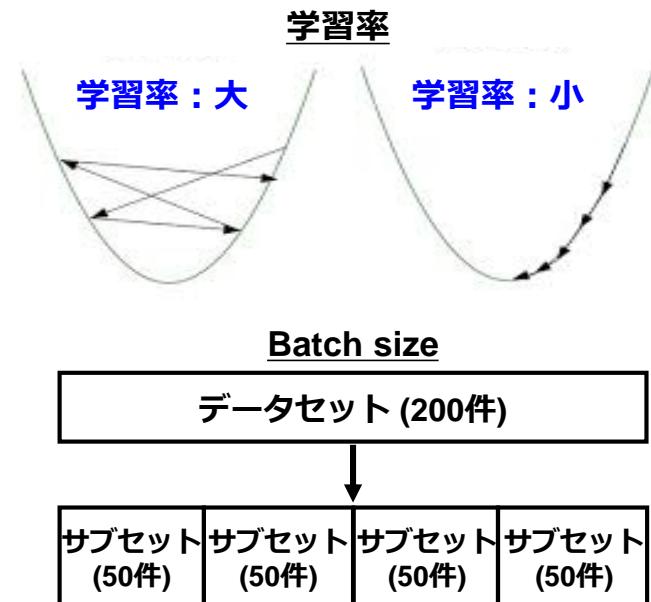
Epoch数 : 1つの訓練データを何回繰り返して学習させるか

⋮

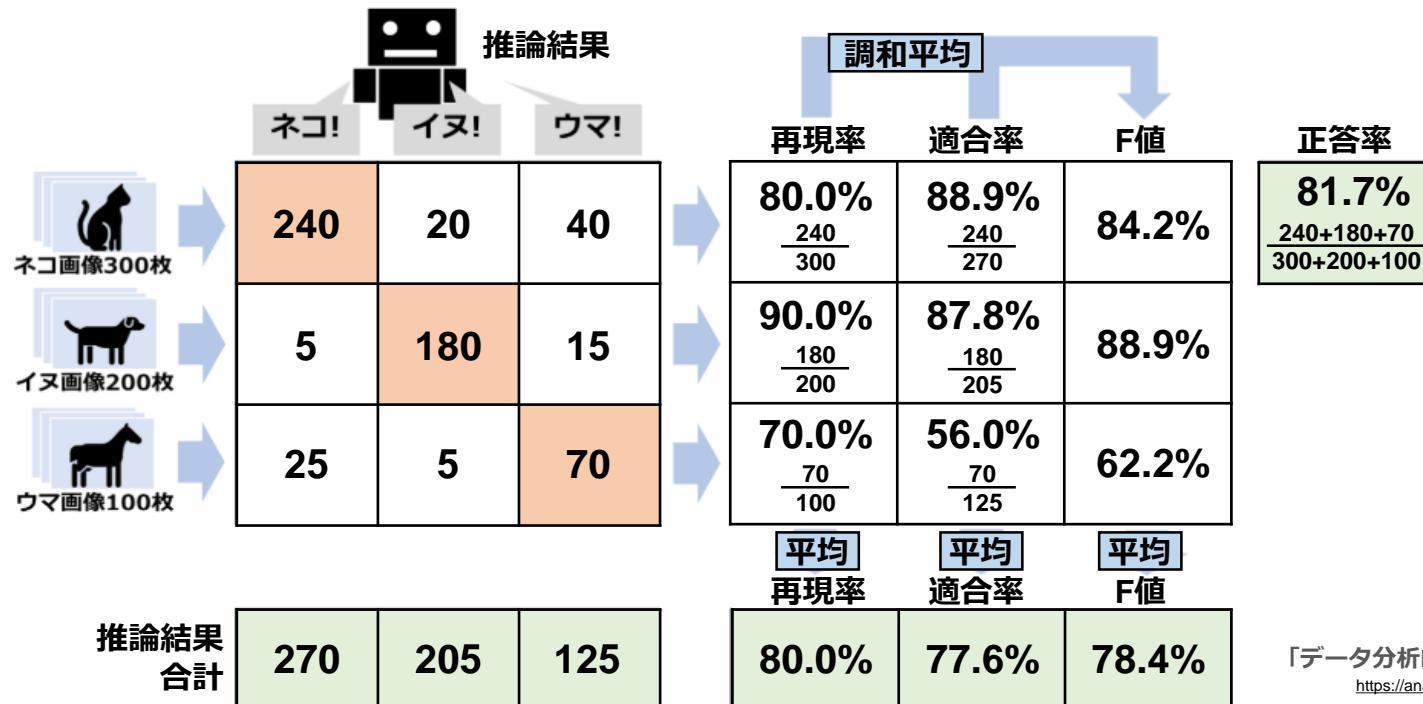
他にもOptimizer、畳み込みのフィルタ数、活性化関数など



今回は学習率、Batch size、Epoch数の最適化を実施



## ■ 評価指標(多クラス分類問題)



「データ分析Navi」より引用  
<https://analysis-navi.com/?p=553>

正答率 : Accuracy

全体に占める正解の割合  
画像枚数にバラツキがある場合は不向き

再現率 : Recall

正解をどれだけ取り逃さなかったか

適合率 : Precision

分類結果がどれだけ正しいか

F値 : F-measure

PrecisionとRecallの良いところ取り

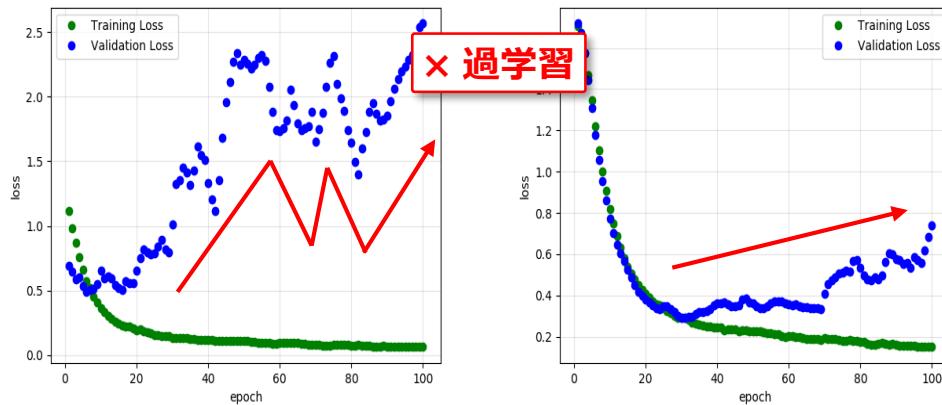
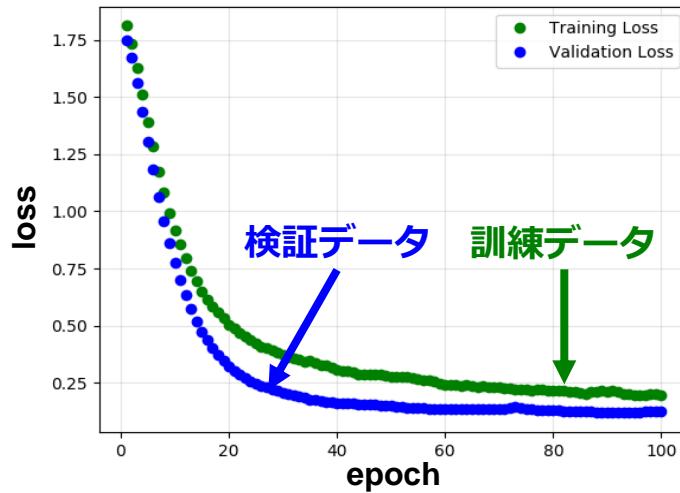
## ■ プログラム作成



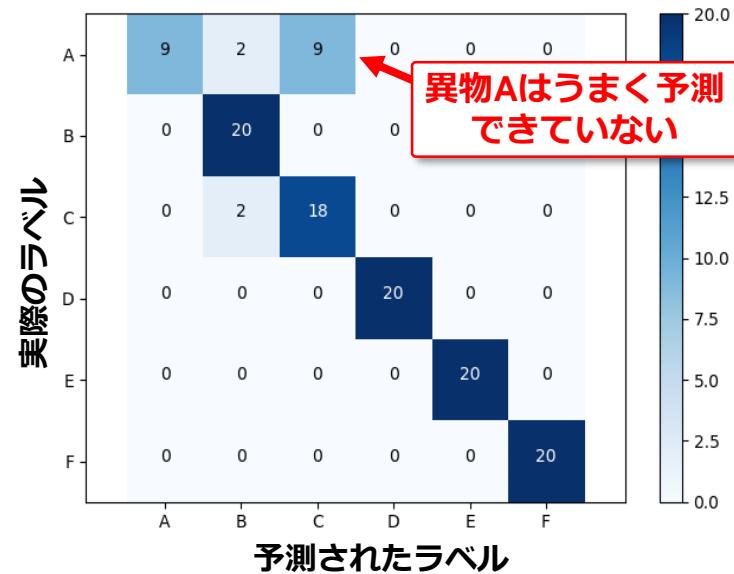
```
276     channel_shift_range=5.0,      # -5~5の間でランダムに画素値を足す
277     brightness_range=[0.3,1.0],   # 0.3~1.0の間でランダムに明度を足す
278     fill_mode='nearest'         # 处理した際の余白を埋める
279   )
280
281 validation_datagen=ImageDataGenerator(rescale=1.0/255)
282
283 train_generator=train_datagen.flow_from_directory(
284   train_dir,
285   target_size=(input_image_size,input_image_size),
286   batch_size=batch_size,
287   class_mode='categorical',
288   shuffle=True
289 )
290
291 validation_generator=validation_datagen.flow_from_directory(
292   validation_dir,
293   target_size=(input_image_size,input_image_size),
294   batch_size=batch_size,
295   class_mode='categorical',
296   shuffle=True
297 )
298
299
300 model_checkpoint = ModelCheckpoint(
301   filepath=os.path.join(parent_path / 'models' / theme_name / 'checkpoint' / (net_type + '_model_{epoch:02d}_{val_loss:.2f}.h5') ),
302   monitor='val_loss',
303   period=150,
304   verbose=1)
305
306 print(net_type)
307 history=model.fit_generator(train_generator,
308   epochs=n_epochs,
309   verbose=1,
310   validation_data=validation_generator,
311   callbacks=[model_checkpoint, CSVLogger(parent_path / 'models' / theme_name / 'csvlogger' / (file_name+'.csv') ) ])
```

## ■ モデルの選定方法

Loss-curve (学習の様子)



Confusion-matrix (混同行列)



評価指標

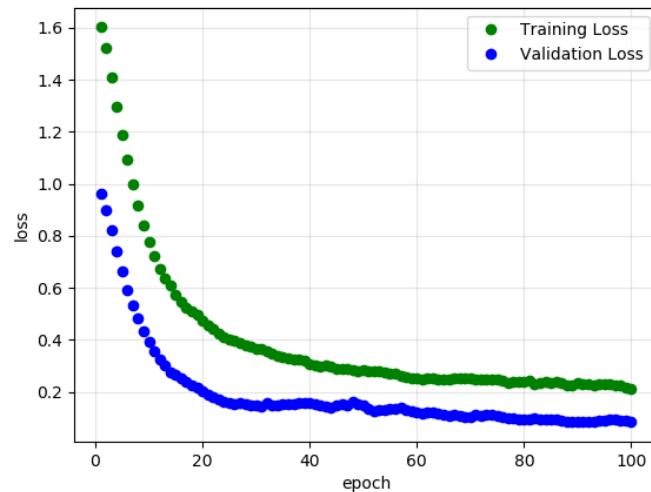
- 正答率 (Accuracy)
- 再現率 (Recall)
- 適合率 (Precision)
- F値 (F-measure)

## ■ モデルの評価結果まとめ

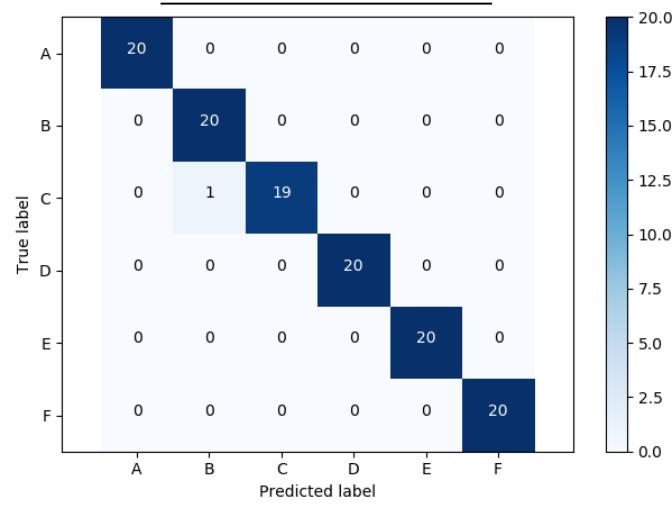
学習条件				正答率 (%)	予測結果						
Base model	学習率	Batch size	Epoch		砂利	BB	芒硝泡	落下物	筋欠陥	リーム	Ave.
VGG-16	1e-5	16	200	91.7	85	80	90	100	100	100	93
Xception	1e-6	16	150	92.5	65	100	80	100	100	100	91
MobileNet	1e-5	8	100	95.0	100	100	95	100	100	100	99



Loss-curve



Confusion-matrix



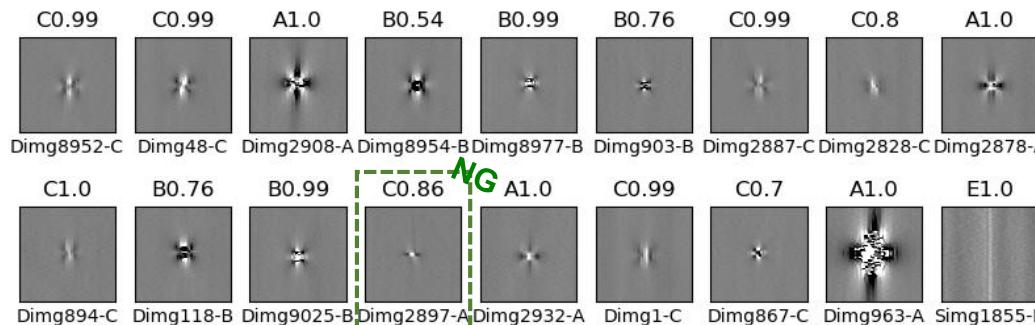
学習条件最適化によって過学習することなく95%の正答率を示した

## ■ PoCにおける評価検証フェーズ

十分な精度を持つモデルを作ることが検証のゴールか？

### 実現性

- データ収集環境は？ → ○
- 課題を解決できるモデル構築は可能か？ → ○



+

### 業務オペレーション

- 予測結果のレスポンス性はどれくらい必要か？
- 現場の人の業務感覚と合っているか？オペレーション可能か？

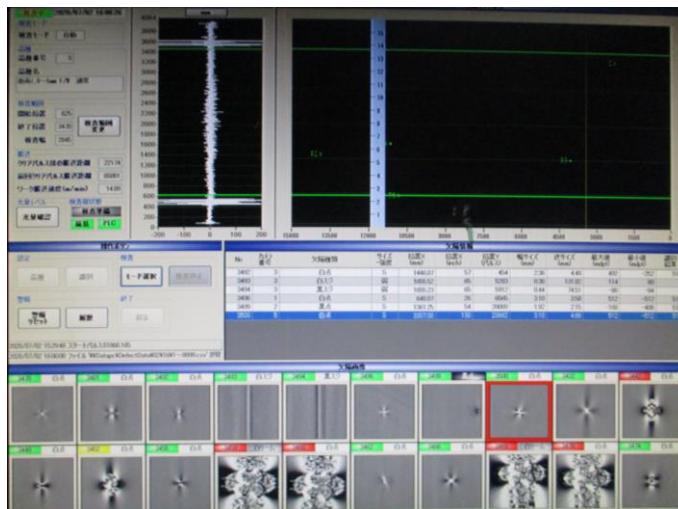
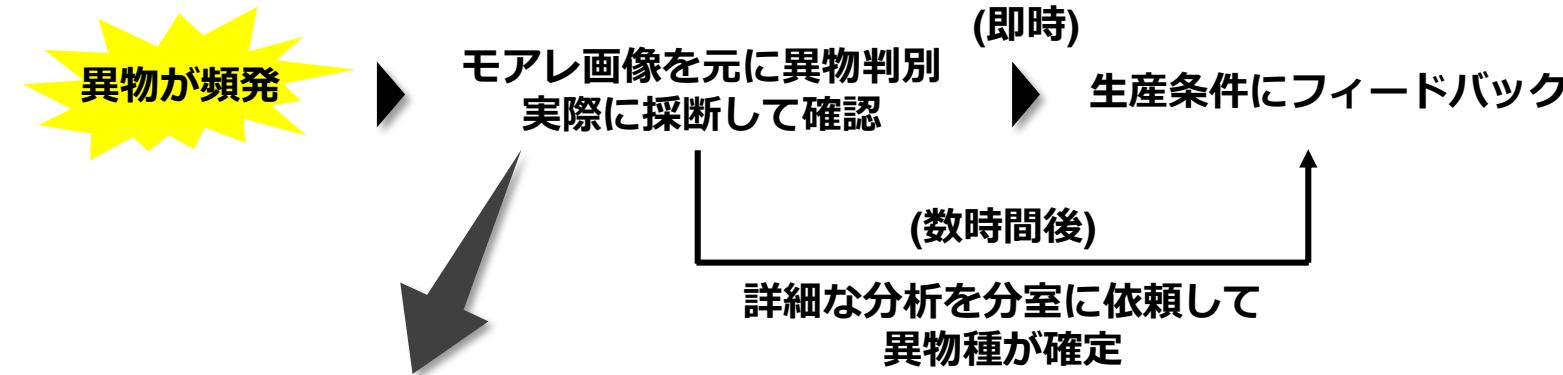
### 効果とコスト

- AIを使った業務改善、コスト削減によるROIは？

## ■ モアレ検査工程におけるAI活用提案

## 1. 詳細な異物発生状況の可視化

これまでは・・・



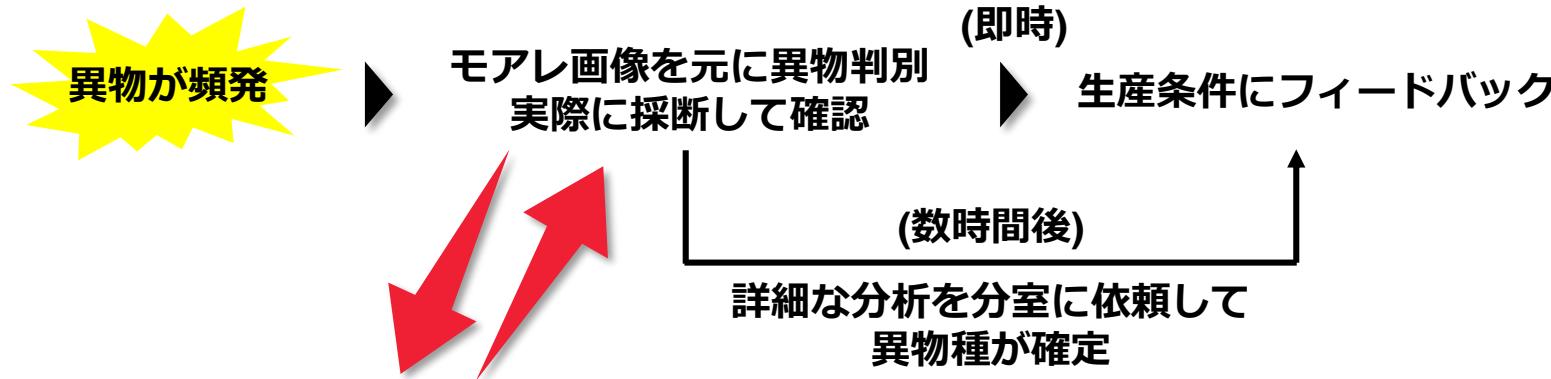
詳細な欠陥種が表示されない(黒, 白等の表示のみ)  
本来の欠陥種はBB, OBB, 芒硝泡, 砂利など様々

- 採断の時間によるロス
  - 判別する人による異物種のバラツキ

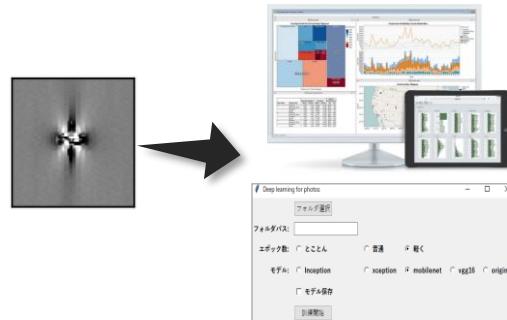
## ■ モアレ検査工程におけるAI活用提案

### 1. 詳細な異物発生状況の可視化

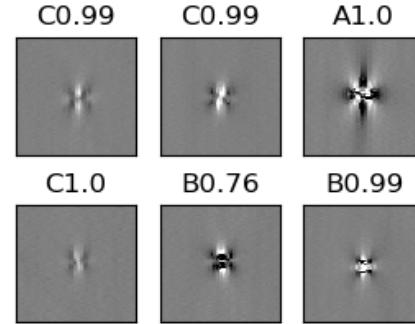
AI導入後は・・・



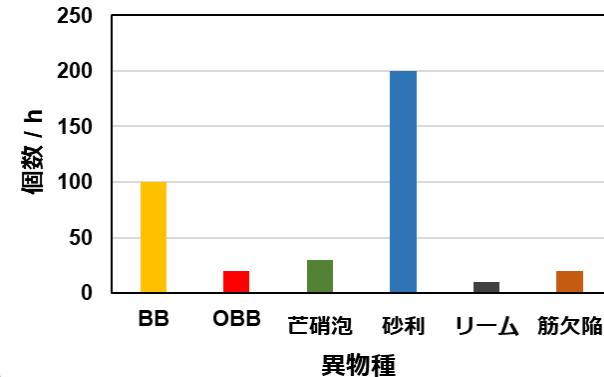
#### 1. 出力された画像を取り込み



#### 2. AIモデルで判別



#### 3. 異物の発生状況を詳細に可視化



👍 フィードバックまでの時間短縮

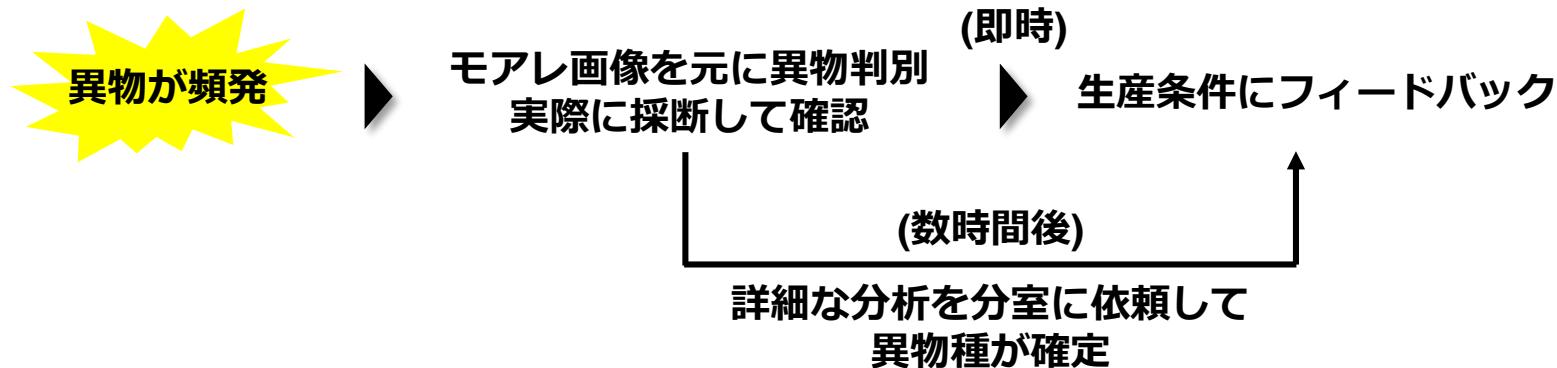
👍 判別精度の向上

## ■ モアレ検査工程におけるAI活用提案

### 2. 異物原因特定の効率化・ノウハウの蓄積

異物を低減する生産条件の最適化手法はないのか?  
→ まずは異物と生産条件の紐づけ(教師データ)が必要

これまでは・・・



## ■ モアレ検査工程におけるAI活用提案

### 2. 異物原因特定の効率化・ノウハウの蓄積

異物を低減する生産条件の最適化手法はないのか?  
→ まずは異物と生産条件の紐づけ(教師データ)が必要

AI導入後は・・・



モアレ画像を元に異物判別  
実際に採断して確認  
+ 反映した画像を保存

(即時)



生産条件にフィードバック  
+ フィードバック方法を記録

(数時間後)



過去の分析画像と照合  
分析結果を蓄積



ノウハウの蓄積

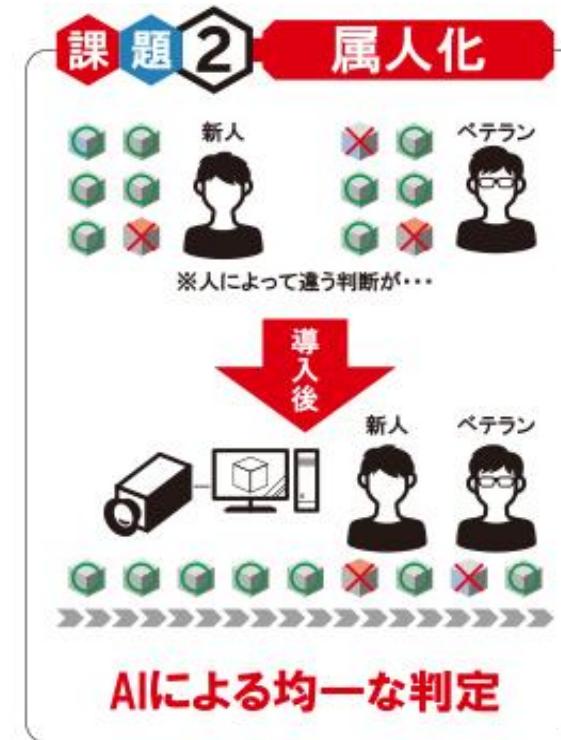
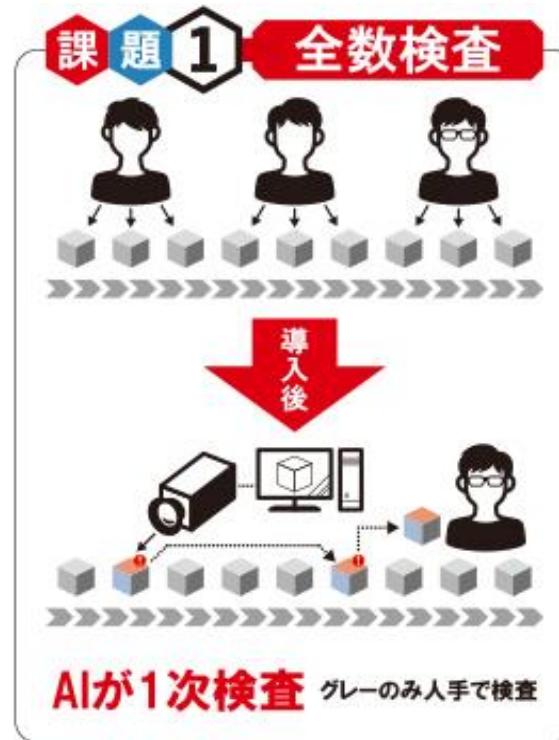


判別精度の向上

## ■ モアレ検査工程におけるAI活用提案

### 3. 検査工程の省力化

正確な紐づけができるようになったら(教師データが揃つたら)・・・



人件費/工数の削減



検査精度のバラツキ低減



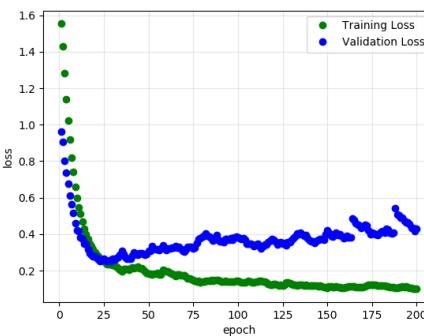
## ■ (例)学習率

Model : VGG-16

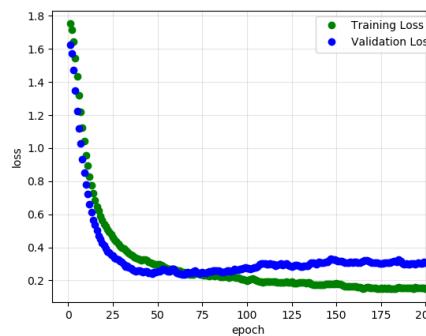
Epoch数 : 200

Learning rate	Batch size	Val loss	Val acc	Test acc	Precision						Recall						F1-score								
					A	B	C	D	E	F	avg	A	B	C	D	E	F	avg	A	B	C	D	E	F	
1.00E-03	64	0.41	0.89	87.5	1.00	0.80	0.78	1.00	1.00	1.00	0.93	0.85	0.80	0.90	1.00	1.00	1.00	0.93	0.92	0.80	0.84	1.00	1.00	0.93	
1.00E-04	64	0.22	0.92	91.7	1.00	0.80	0.78	1.00	1.00	1.00	0.93	0.85	0.80	0.90	1.00	1.00	1.00	0.93	0.92	0.80	0.84	1.00	1.00	0.93	
1.00E-05	64	0.38	0.88	89.2	1.00	0.77	0.70	0.91	1.00	1.00	0.90	0.45	1.00	0.80	1.00	1.00	1.00	0.88	0.62	0.87	0.74	0.95	1.00	1.00	0.86
1.00E-06	64	1.24	0.69	70	1.00	0.49	0.87	0.00	0.67	0.67	0.62	0.20	1.00	0.65	0.00	1.00	1.00	0.64	0.33	0.66	0.74	0.00	0.80	0.80	0.56

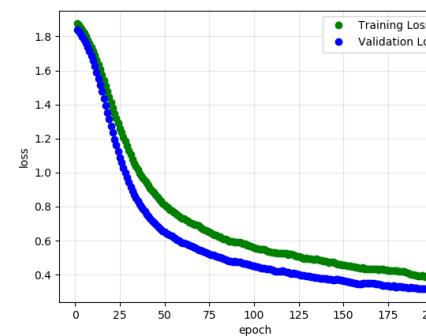
lr=1e-3



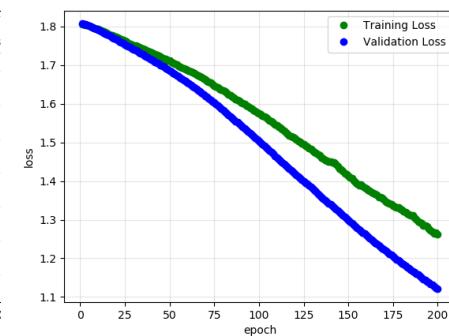
lr=1e-4



lr=1e-5



lr=1e-6

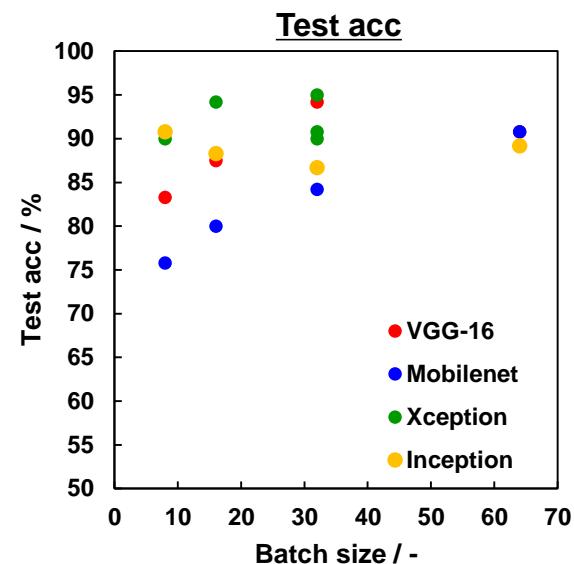
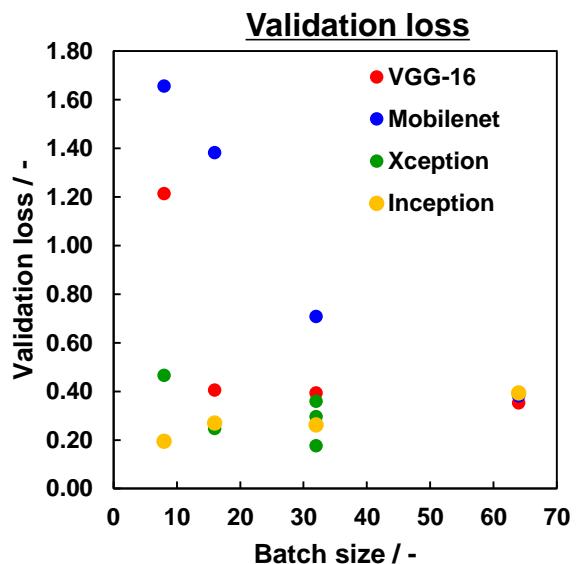
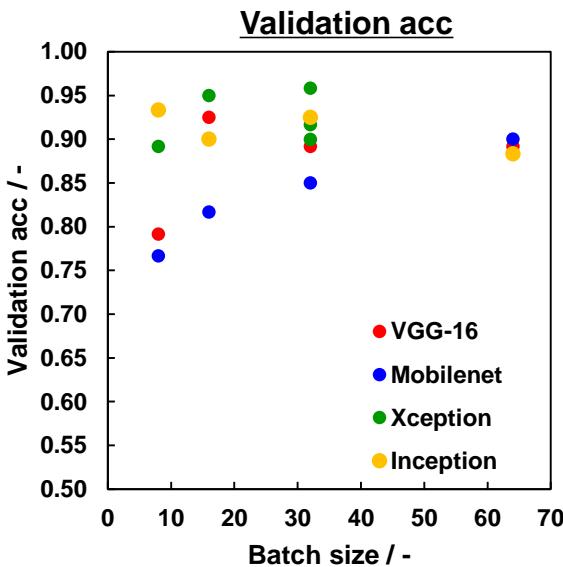


lr=1e-5より小さいときに過学習が起こっていない

lr=1e-6だと学習速度遅すぎ

モデルによっても最適な学習速度ありそう

## ■ (例)Batch size



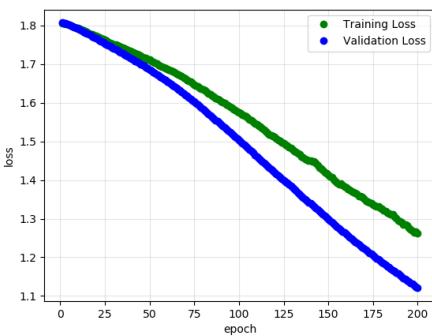
Batch size小さいとモデルによってかなり差あり

## ■ (例)Epoch数

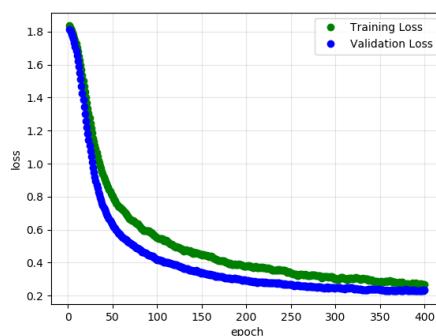
Model : VGG-16

Epoch	Learnin g rate	Batch size	Val loss	Val acc	Test acc	Precision							Recall							F1-score						
						A	B	C	D	E	F	avg	A	B	C	D	E	F	avg	A	B	C	D	E	F	avg
200	1.00E-05	64	0.38	0.88	89.2	1.00	0.77	0.70	0.91	1.00	1.00	0.90	0.45	1.00	0.80	1.00	1.00	1.00	0.88	0.62	0.87	0.74	0.95	1.00	1.00	0.86
400	1.00E-05	64	0.31	0.87	90.8	1.00	0.80	0.72	1.00	1.00	1.00	0.92	0.75	0.80	0.90	1.00	1.00	1.00	0.91	0.86	0.80	0.80	1.00	1.00	1.00	0.91
700	1.00E-05	64	0.35	0.87	85.8	0.94	0.80	0.77	1.00	1.00	1.00	0.92	0.85	0.80	0.85	1.00	1.00	1.00	0.92	0.89	0.80	0.81	1.00	1.00	1.00	0.92
1000	1.00E-05	64	0.31	0.87	86.7	1.00	0.80	0.78	1.00	1.00	1.00	0.93	0.85	0.80	0.90	1.00	1.00	1.00	0.93	0.92	0.80	0.84	1.00	1.00	1.00	0.93

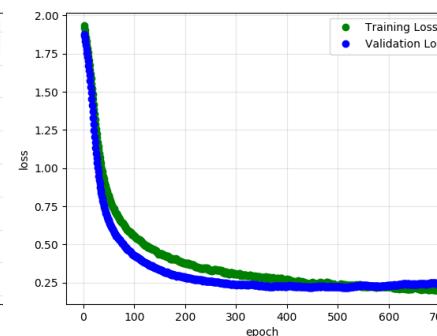
Epoch=200



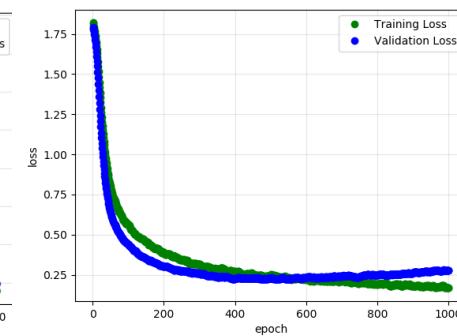
Epoch=400



Epoch=700



Epoch=1000

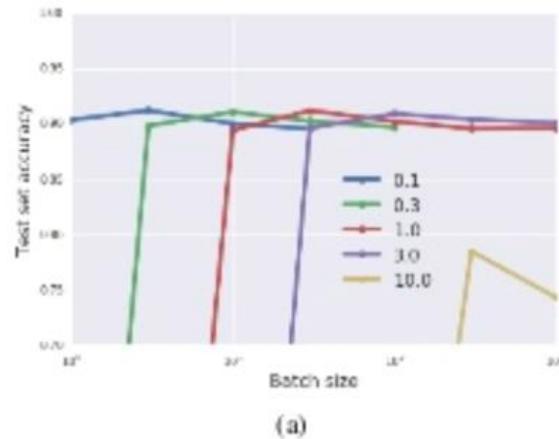


Epoch=200だと少なすぎる  
Epoch=1000だと若干過学習気味

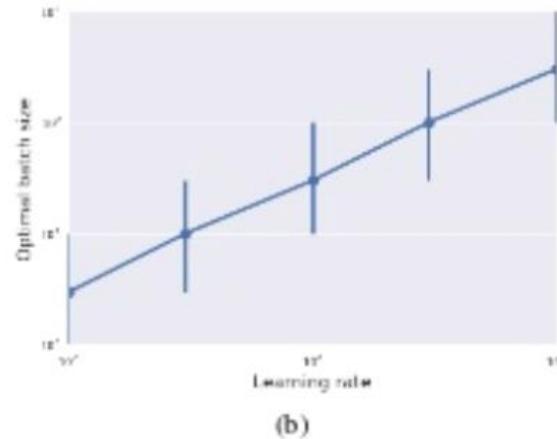
## 実験3-1：最適バッチサイズと学習率の関係

- MNISTで学習

- (a)：バッチサイズと正解率, (b)学習率と最適バッチサイズ



(a)



(b)

- ルールの通り、バッチサイズと学習率が比例関係になっている。

$$B_{opt} \propto \epsilon$$

# ■ 社内ニーズの聞き込み調査

時期	情報元	分野	ライン	目的	内容	判定
2019年度	6研	分析	画像解析	時間短縮	・顕微鏡画像から硫化ニッケルを自動判定（2019年3研WS）	○済
2019年度	3研	研究	性能予測	時間短縮	・積層膜は光学理論に基づいて性能が決まるので十分	×無意味
2019年度	BDG/ 高田副技師	生産	堺SP3	時間短縮 品質向上	・生産条件は紙ベースで保管されており電子化必要	×頓挫
2019年度	BDG/ 高田副技師	生産	複層	時間短縮	・製品の傷を顕微鏡観察してどの工程で生じた傷が自動判定しても、そもそも傷は多く発生しない、顕微鏡像でどの工程の傷か分かる	×無意味
2020年4月	高松所長 小原主席	生産 研究			・川越は化合物探索メイン ・硝子窯の操業条件に適用するのはハイリスク ・S-UV、くさびHUD、ISRA、色替え、ネタは色々ある	-
2020年4月	7研/都築主席	生産 研究	FL、BL、 QSB	品質向上 省力化	・硝子窯の重油低減、色替え短縮に生かせれば一番コスト メリット大きいが、現場はシミュレーション系を信じない ・ガラス強度はデータにバラつきあり不適 ・合わせ（ヘッドフォームの跳ね返りNG、亀裂）に課題あるが、 炉だけでなく洗浄、厚みなど様々な要素が影響する ・亀裂は合わせ前のPVB厚みを測ってるが無意味であることを 示せば省力化になる、合わせ後のPVB厚みが重要 ・型替えロスを少なくできれば生産効率アップになる ・強化（破碎数、シャープエッジ）は炉の条件がダイレクトに 効くので生かしやすいがコストインパクトは疑問	-
2020.4.16	TSG/ 坂口副技師	生産	BL など 色々	異常事前検知 品質向上	・合わせ、強化の炉の運転状況はほぼ電子化。品質データなし。 ・研究所にデータサーバを置き、生産設備の運転状況を 吸い出せるようにしてアイデアを試す環境を整備しては？	- ◎取り組める
2020.4.20	製造二課/ 中尾課員	生産	FL1	欠陥検出 品質向上	・モアレ検査での異物自動判定 ・同検査での硫化ニッケルの自動判定 ・同検査での蒸気の影響排除 ・DG→M切り替え時のコバルトの効率排出条件の自動導出	◎取り組める △難易度高 △難易度不明 △難易度高
今後	品管/早川課長 三重硝子/ 家入技師	生産	BL、QSB	品質向上 省力化	・工場はほとんど紙ベース ・EC日報（品質）は電子化されている。	-

# ■ 社内ニーズの聞き込み調査

## 1. スパッタ関連(研究所)

- 膜構成変更時の光学特性予測

層順(Glass/SiAlN/ITO/ZnSnOとGlass/ZnSnO/SiAlN/ITO)や  
層数によって最適解が異なる

→ 交互作用が大きくパラメーター毎の最適解はない  
また、膨大なデータを準備する必要があり不向き

- 热処理後、合わせ後の特性予測

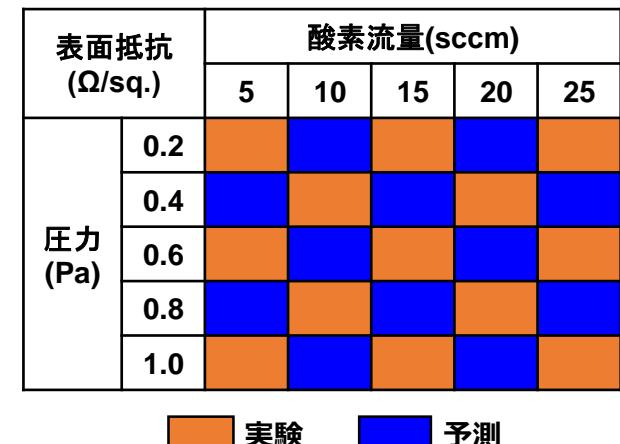
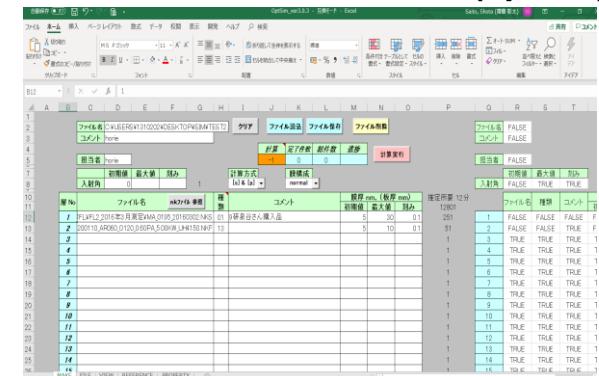
热処理前、合わせ前の条件が異なるとその後の特性も大きく異なる  
→ データセットの準備が困難

- 成膜条件変更時の特性予測

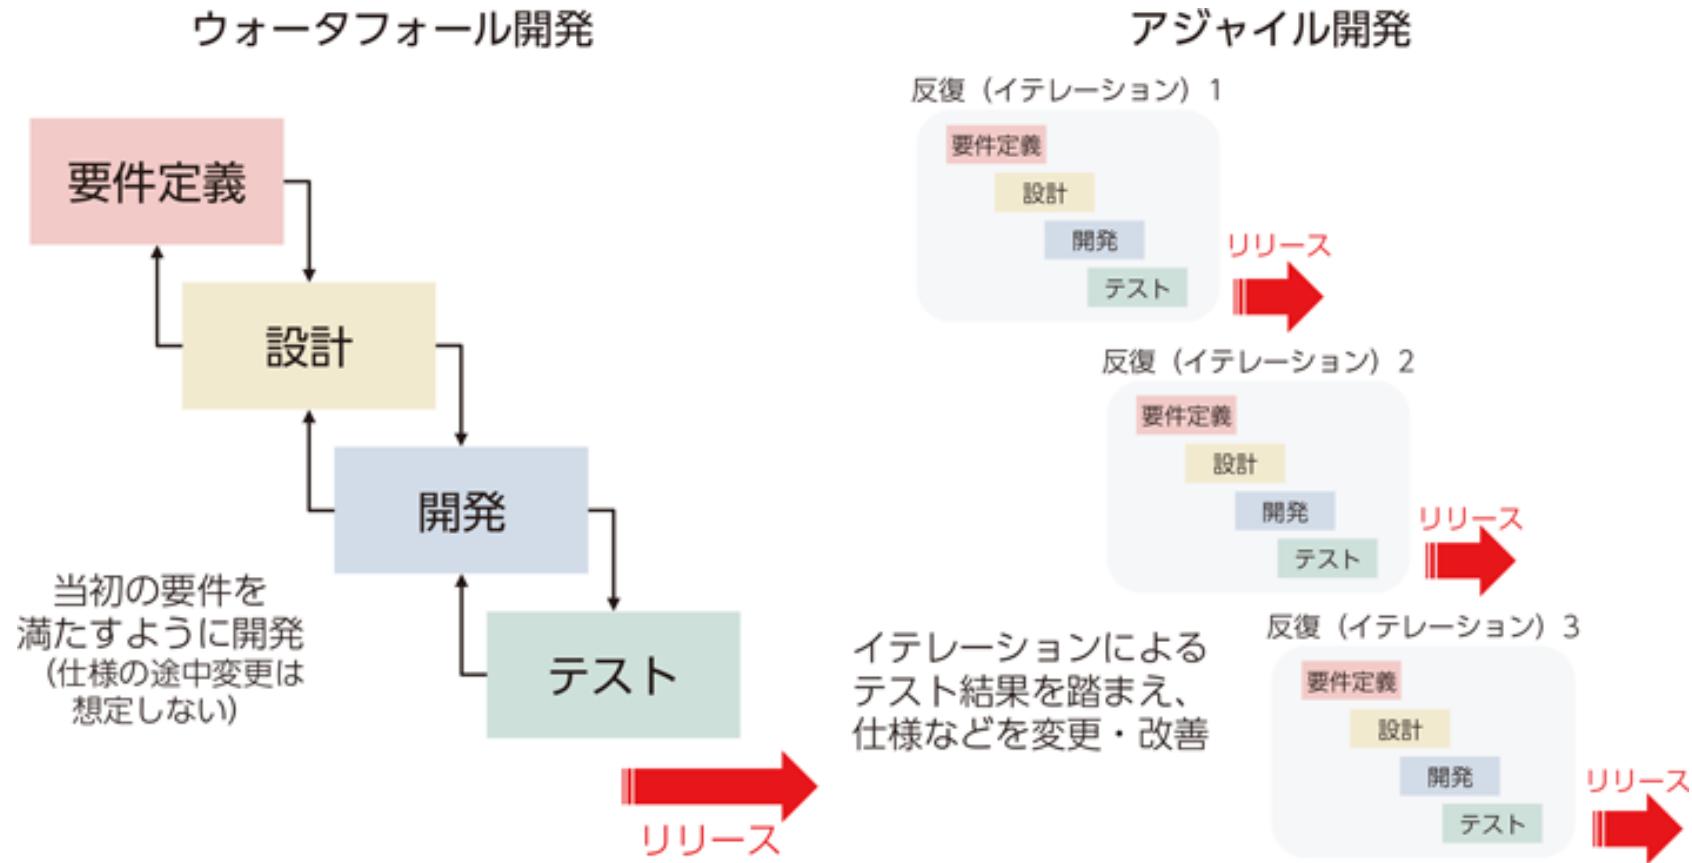
内装条件ならば実験回数を減らすことが可能

→ 例えば2パラメーター5条件=25回の実験を13回の実験に  
減らすことができる

光学シミュレーションソフト(optsim)

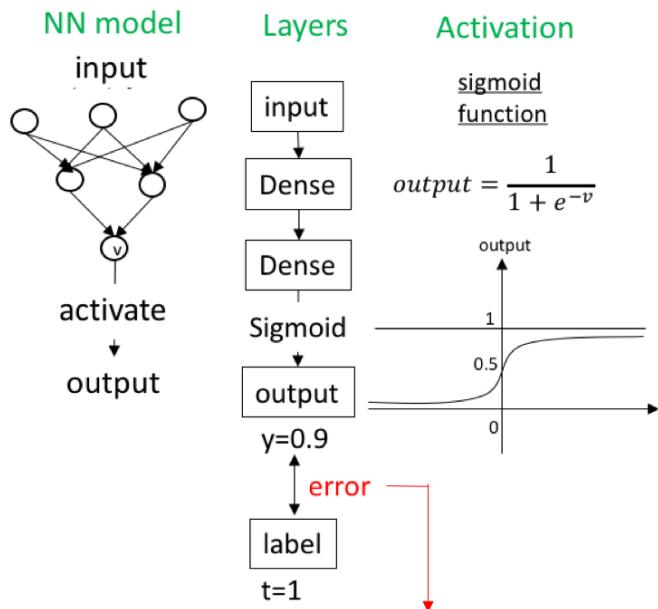


## ■ 開発の流れ



# ■ 損失関数(loss-function)

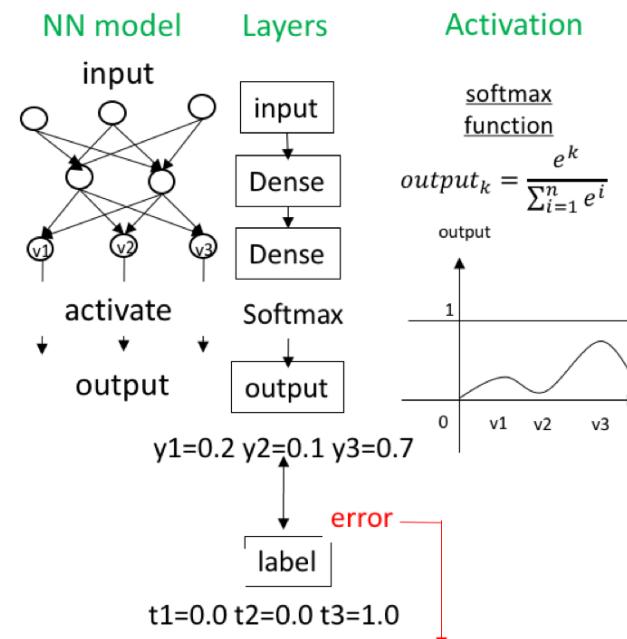
1.2値分類



二値クロスエントロピー(BCE)

$$L = -t \log y - (1 - t) \log(1 - y)$$

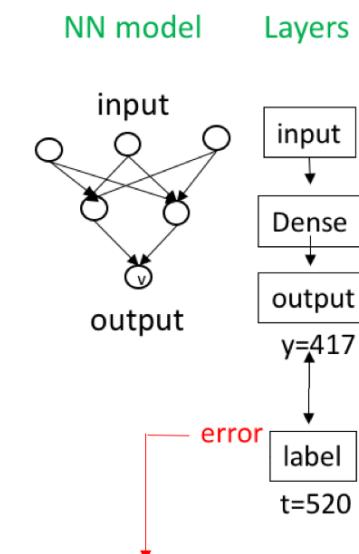
2.多クラス分類



クロスエントロピー(CE)

$$L = - \sum_{i=0} t_i \log y_i$$

3.回帰



平均二乗誤差(MSE)

$$L = \frac{1}{2} (t - y)^2$$

[https://www.renom.jp/ja/notebooks/tutorial/basic\\_algorithm/lossfunction/notebook.html](https://www.renom.jp/ja/notebooks/tutorial/basic_algorithm/lossfunction/notebook.html)

<https://www.atmarkit.co.jp/ait/articles/1804/24/news134.html>

## ■ 置み込みNN

1 <sub>x1</sub>	1 <sub>x0</sub>	1 <sub>x1</sub>	0	0
0 <sub>x0</sub>	1 <sub>x1</sub>	1 <sub>x0</sub>	1	0
0 <sub>x1</sub>	0 <sub>x0</sub>	1 <sub>x1</sub>	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		

Convolved  
Feature

元画像

0	0	3	3	3
0	3	3	3	3
0	0	3	3	3
0	0	5	5	5
0	0	5	5	5

×

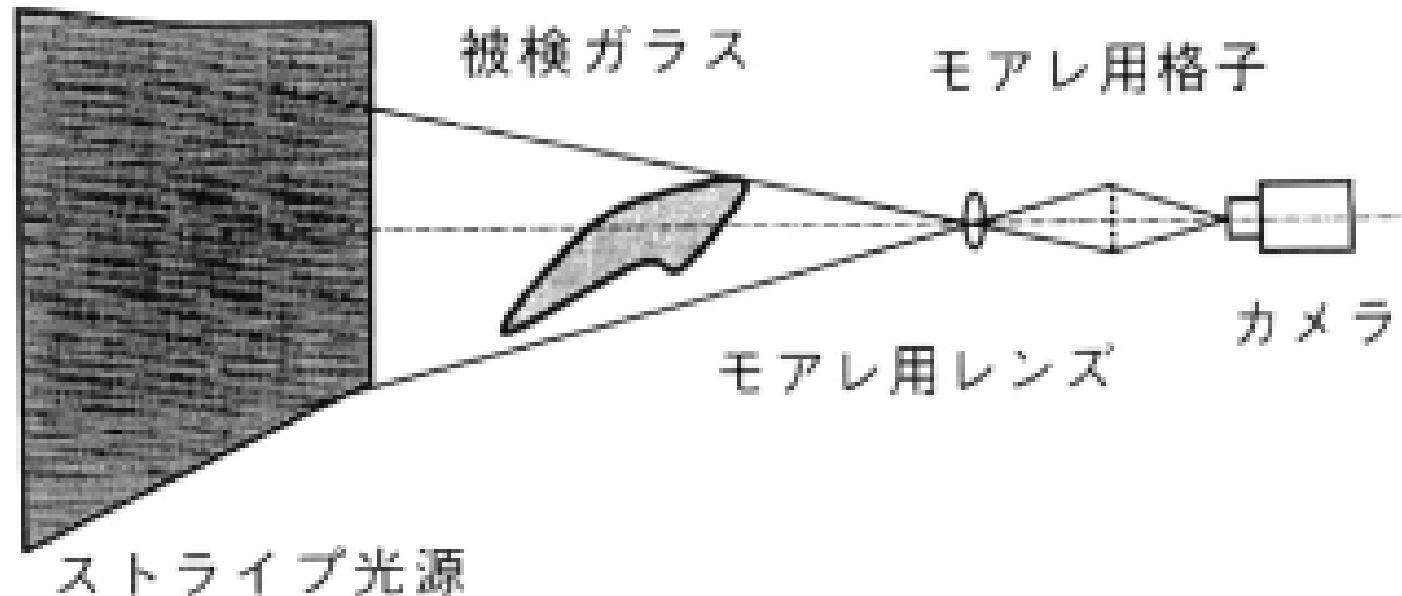
3×3フィルタ

0	0.2	0
0.2	0.2	0.2
0	0.2	0

a	b	

1.2	3.0	3.0
1.8	2.4	3.0
1.0	3.6	4.6

## ■ モアレ検査



## ■ 社内ニーズの聞き込み調査

### 1. スペッタ関連(建築用)

- SP3における生産条件出しの簡易化

品種によってベテラン不在時には条件出しにかなり時間を要する

生産条件データは基本紙ベース

電子データでも残っているが、抽出可能なデータは2日分程度

→ 十分な量・質のデータセットを用意することが困難

- 複層工程における傷対策

洗浄・搬送キズの発生原因を早期に特定したい

→ キズ発生頻度が高くない

顕微鏡で確認すればある程度対策が立てられるため効果は限定的

Low-E膜の洗浄キズ



# ■ 社内ニーズの聞き込み調査

## 2. 加工部関連

- 品質と加工条件の結び付け

BL6・DBX・MBT-1の運転状況は可視化済み

→ 運転状況データを取得する環境は構築されているが、対になる品質データが存在しない  
ガラス強度は洗浄、板厚等の条件も効いてくるため品質との結び付けが難しい

### 加工条件の可視化

